

DERİN ÖĞRENME İLE GÜNEŞ PANELİ HATA TESPİTİ (PV FAULT DETECTION WITH DEEP LEARNING)

Efsa SEZER
Bilgisayar Mühendisliği
İstanbul Topkapı Üniversitesi
İstanbul/Türkiye
efsasezer@stu.topkapi.edu.tr

Asuman ULUSOY
Bilgisayar Mühendisliği
İstanbul Topkapı Üniversitesi
İstanbul/Türkiye
asumanulusoy@stu.topkapi.edu.tr

Mert Can SARIBIYIK
Bilgisayar Mühendisliği
İstanbul Topkapı Üniversitesi
İstanbul/Türkiye
mertcansaribiyik@stu.topkapi.edu.tr

Cevat RAHEBİ
Yazılım Mühendisliği
İstanbul Topkapı Üniversitesi
İstanbul/Türkiye
cevatrahebi@topkapi.edu.tr

ÖZET : Bu makale, fotovoltaik (PV) sistemlerde derin öğrenme temelli bir hata tespiti projesini ayrıntılı bir şekilde incelemektedir. Günümüzde artan fotovoltaik enerji kullanımı, sürdürülebilir enerji kaynaklarına yönelik talebin artmasıyla paralel olarak, fotovoltaik sistemlerin güvenilirliği ve performansı önemli bir odak noktası haline gelmiştir. Bu bağlamda, makalede sunulan proje, PV sistemlerinde meydana gelebilecek çeşitli hataları tanımlamak ve belirlemek amacıyla derin öğrenme yöntemlerini kullanmaktadır. Özellikle güneş panellerinin sayılarının artmasıyla birlikte, insan gözüyle bu tespitin karmaşık ve zorlu bir süreç haline gelmiştir. Derin öğrenme tabanlı hata tespit sistemi, bu zorlu süreci başarılı bir şekilde yöneterek, fotovoltaik enerji sistemlerinin güvenilirliğini artırmayı hedeflemektedir. Yapay sinir ağları ve derin öğrenme algoritmaları, PV sistemlerinde ortaya çıkabilen arızaları otomatik olarak tanımlamak ve sınıflandırmak için eğitilmiştir.

ANAHTAR KELİMELELER: Fotovoltaik sistemler, Derin öğrenme, Hata tespiti, Yapay sinir ağları

I. GİRİŞ

Son yıllarda, küresel ısınma ve fosil yakıtların azalması güneş, rüzgar, hidroelektrik ve jeotermal enerji gibi yenilenebilir enerji kaynaklarına (YEK) olan ilgiyi arttırmıştır. Bu enerji kaynaklarının arasında, güneş enerjisi dikkat çeken YEK türlerinden biridir. Güneş enerjisi, muazzam potansiyel gücü ve güvenli enerji üretimi gibi özellikleri sayesinde daha kabul edilebilir ve gelecek vaat eden bir enerji kaynağı haline gelmiştir [1][2].

Günümüzde, fotovoltaik (PV) sistemler, temiz enerji üretiminde önemli bir role sahip olup, enerji sektörünü dönüştürmekte ve sürdürülebilirlik hedeflerine katkıda bulunmaktadır [3]. Ancak, PV sistemlerinin performansını etkileyen çeşitli faktörler, arızalar ve hatalar meydana

gelebilmektedir. Bu hataların erken tespiti ve doğru sınıflandırılması, sistem güvenilirliğini artırmak, bakım maliyetlerini azaltmak ve enerji verimliliğini optimize etmek açısından kritik öneme sahiptir.

Fotovoltaik hata tespiti, geleneksel yöntemlerle genellikle karmaşık ve zaman alıcı olabilir. Bu bağlamda, derin öğrenme teknikleri, büyük veri setleri üzerinde etkili bir şekilde öğrenme yeteneği ile öne çıkmaktadır [4]. Yapay sinir ağları, derin öğrenme algoritmaları ve makine öğrenimi teknikleri, fotovoltaik sistemlerdeki hataları otomatik olarak tanımlama yeteneği ile dikkat çekmektedir.

Bu makalede, fotovoltaik sistemlerde hata tespiti için derin öğrenme yaklaşımını, yapay sinir ağlarının fotovoltaik hata tespiti üzerindeki etkilerini detaylı bir şekilde inceleyeceğiz. Ayrıca, geliştirilen modelin gerçek dünya uygulamalarındaki başarılarına odaklanarak, fotovoltaik sistemlerin güvenilirliğini artırmak için bu yeni yaklaşımın potansiyelini vurgulayacağız.

Bu bağlamda, önerdiğimiz derin öğrenme tabanlı fotovoltaik hata tespiti yönteminin, enerji sektöründe önemli bir kilometre taşı olabileceğine inanmaktayız. Öncü çalışmaların sunduğu başarı örneklerini inceleyerek, derin öğrenme tekniklerinin fotovoltaik sistemlerdeki hataların tespiti ve sınıflandırılmasında ne kadar etkili olduğunu anlamamız mümkündür [5][6].

Bu makale, fotovoltaik enerji sistemlerinin güvenilirliğini artırmak, bakım süreçlerini optimize etmek ve sürdürülebilir enerji üretimine katkı sağlamak amacıyla yapılan bu yenilikçi araştırmayı daha geniş bir kitleyle paylaşmayı hedeflemektedir.

II. LİTERATÜR TARAMASI

Fotovoltaik (PV) sistemlerde hata tespiti, günümüzde enerji sektöründeki önemli bir araştırma alanını oluşturmaktadır. Bu bağlamda, derin öğrenme ve yapay zeka tekniklerinin fotovoltaik hata tespiti üzerindeki etkisini değerlendirmek amacıyla yapılan çeşitli çalışmalar literatürde yer almaktadır.

Wang ve ekibi (2020) tarafından yapılan çalışmada, derin öğrenme tekniklerinin PV sistemlerinde hata tespiti konusundaki uygulanabilirliği incelenmiştir [5]. Yapılan bu çalışma, yapay sinir ağlarının PV sistemlerindeki arızaları tanıma yeteneklerini öne çıkarmaktadır.

Zhang ve diğerleri (2020), fotovoltaik grid-bağlantılı inverterlerde oluşabilecek arızaların teşhisi için yapay sinir ağlarının kullanımını ele alan bir çalışma gerçekleştirmiştir [6]. Bu çalışma, yapay sinir ağlarının PV sistemlerindeki inverter hatalarını etkili bir şekilde tanımlama yeteneğini vurgulamaktadır.

Gupta ve arkadaşları (2021), derin sinir ağlarını kullanarak fotovoltaik sistemlerde hata tespit doğruluğunu artırmaya odaklanan bir çalışma yayınlamıştır [7]. Bu çalışma, derin öğrenme tekniklerinin PV sistemlerindeki hata tespiti performansını önemli ölçüde geliştirebileceğini göstermektedir.

Ayrıca, Chen ve ekibi (2021) tarafından yapılan karşılaştırmalı bir çalışma, farklı makine öğrenimi yaklaşımlarının fotovoltaik sistemlerde hata tespiti üzerindeki etkilerini analiz etmektedir [8]. Bu çalışma, çeşitli makine öğrenimi yöntemlerinin avantajlarını ve zayıf yönlerini ortaya koymaktadır.

FV kapasitesinin 2030 yılında 3,518 TWh'lik enerji üretimini karşılayabileceği tahmin edilmektedir [9].

Kurulum sırasında panelin kırılması veya çatlaması, karlanma, böcek izleri, yanık izleri ve renk değişimi gibi farklı birçok arıza meydana gelebilir. Ayrıca, hatalı lehimleme veya bağlantı gibi üretim hataları da FV panellerin hasarlı olmasına sebep olabilir. Bu tür çeşitli problemler, FV sistemlerinin akım akışını engelleyerek üretim gücünü ve verimliliğini azaltır. Bu nedenle, güneş enerjisi üretim santrallerinde, maksimum verimi sağlamak için panellerin çalışma durumunu izlemek ve arızalı üniteleri değiştirmek veya onarmak gerekir [10][11].

Yapılan literatür taraması, derin öğrenme ve yapay sinir ağlarının fotovoltaik sistemlerde hata tespiti alanında önemli potansiyellere sahip olduğunu göstermektedir. Bu çalışmalar, fotovoltaik enerji sistemlerinin güvenilirliğini artırmak ve bakım süreçlerini optimize etmek amacıyla geliştirilen inovatif yaklaşımları ortaya koymaktadır. Bu bağlamda, bu makalede ele alınan derin öğrenme tabanlı fotovoltaik hata tespiti yöntemi, literatürdeki benzer çalışmaların izinden gitmektedir.

III. MATERYAL & METOT

A. VERİ TOPLAMA

Bu çalışmanın veri toplama aşamasında, güneş panellerindeki arızaları analiz etmek üzere bir dizi güneş paneli resmini içeren bir klasör ve bu resimlere ait arıza yüzdelerini içeren bir CSV dosyası kullanılmıştır.

Toplamda 2624 adet resim içeren bu veri kümesi, gerçek dünya koşullarında maruz kalan güneş panellerinin çeşitli arızalarını yansıtmaktadır.

Veri kümesinin oluşturulması sürecinde, her bir resim 300x300 piksel boyutlarındadır. Bu pikseller, güneş panellerindeki detayları yakalamak ve arızaların doğru bir şekilde sınıflandırılabilmesi için kullanılmıştır. Her bir resmin ayrı bir kimlikle belirlendiği ve bu resimlere ait arıza yüzdelerini içeren bir CSV dosyasının bulunduğu bir veri tablosu oluşturulmuştur.

Çizelge 1. İki Veri Setinin Birleştirilmiş Hali

	Fault	0	1	2	3	4	5	6	7	8	...	89999
0	1.0	14	14	14	15	16	17	17	17	17	...	4
1	1.0	29	29	29	28	28	29	29	29	28	...	10
2	1.0	29	29	30	30	30	30	30	30	30	...	0
3	0.0	35	35	35	36	36	36	36	36	37	...	0
4	1.0	39	39	40	40	40	40	41	41	41	...	0
....

Çizelge 1'de gösterildiği gibi, bu veri tablosu 2624 satır ve 90001 sütundan oluşmaktadır. Her bir sütun, bir resmin piksellerini temsil ederken, son sütun olan "fault" sütunu, her bir resmin arıza yüzdesini göstermektedir. Bu yapı, veri setinin detaylı bir şekilde temsilini sağlamak ve derin öğrenme modelinin eğitilmesi için güçlü bir temel oluşturmaktadır.

Ayrıca, Çizelge 1'de gösterilen veri setinin tablolastırılmış hali, her bir resmin piksel değerlerini ve bu resimlere ait arıza yüzdelere ilişkin kapsamlı bir veri setini göstermektedir. Bu çizelge, projemizin veri toplama aşamasında elde ettiğimiz kapsamlı ve çeşitli veri kümesini daha iyi anlamamıza yardımcı olmaktadır.

Bu veri toplama süreci, projemizin temelini oluşturan güçlü bir veri setinin elde edilmesini sağlamıştır, bu da derin öğrenme modelimizin etkili bir şekilde eğitilmesini ve güneş panellerindeki arızaların doğru bir şekilde sınıflandırılmasını hedeflemektedir.

B. VERİ ÖN İŞLEME

İlk adım olarak, güneş paneli resimlerinin bulunduğu veri setini projemize yüklüyoruz. Bu süreçte, resimleri bir liste içerisine ekliyoruz. Resimlerin listeye karışık bir şekilde eklenmiş olabileceği durumları önlemek için, liste üzerinde sort metodunu kullanarak resimleri alfabetik sıraya göre düzenliyoruz.

Daha sonra, resim listesini sırayla dolaşarak her bir resmi matrix formuna dönüştürüyoruz. Bu, resimleri sayısal verilere çevirerek bilgisayar tarafından işlenebilir hale getirme işlemidir. Elde ettiğimiz her bir matrixi, bir pandas DataFrame'e ekliyoruz.

Çizelge 2. Veri Setinin Normalize Edilmiş Hali

	Fault	0	1	2	3	4	5	6	...	89999
0	1.0	0.105263	0.105263	0.106061	0.113636	0.123077	0.13076	0.130769	...	0.030303
1	1.0	0.218045	0.218045	0.219697	0.212121	0.215385	0.223077	0.223077	...	0.075758
2	1.0	0.218045	0.218045	0.227273	0.227273	0.230769	0.230769	0.230769	...	0.000000
3	0.0	0.263158	0.263158	0.265152	0.272727	0.276923	0.276923	0.27692	...	0.000000
4	1.0	0.293233	0.293233	0.303030	0.303030	0.307692	0.307692	0.315385	...	0.000000
....

Bu DataFrame, her bir güneş paneli resminin sayısal temsilini içerir ve modelin eğitimi için giriş verisi olarak kullanılacaktır.

C. VERİ NORMALİZASYONU

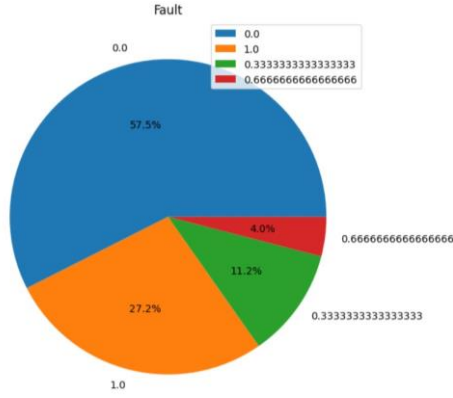
Derin öğrenme modelimizin daha etkili ve performanslı olabilmesi için, büyük boyuttaki veri kümesini daha küçük boyutlara dönüştürmek amacıyla normalizasyon işlemi uygulanmıştır. Normalizasyon işlemi, projemizin derin öğrenme modelinin daha iyi öğrenmesini ve genelleme yapmasını desteklemek üzere başarılı bir şekilde uygulanmıştır. Bu işlem, verileri 0 ile 1 arasında ölçekleyerek, piksel değerlerinin daha homojen bir dağılıma sahip olmasını sağlar. Çizelge 2, normalizasyon işlemi uygulanmış piksel değerlerini ve arıza yüzdelere ilişkin tablolastırılmış bir veri setini göstermektedir.

Normalizasyon süreci, her bir piksel değerini (0 ile 255 arasında değişen) 0 ile 1 arasında bir değere dönüştürmektedir. Bu, modelin öğrenme sürecini stabilize eder ve aynı zamanda ağırlıkları daha etkili bir şekilde güncellemesine yardımcı olur.

Çalışmamız kapsamında, normalizasyon işlemi, projemizde kullanılan 300x300 piksel boyutundaki güneş paneli resimlerindeki piksel değerlerine uygulanmıştır. Bu sayede, derin öğrenme modeli, daha geniş bir öğrenme aralığına sahip olacak ve eğitim süreci daha hızlı ve kararlı bir şekilde gerçekleşecektir.

D. VERİ GÖRSELLEŞTİRME

Veri setimizin arıza yüzdelere ilişkin daha etkili bir şekilde anlamak ve sunmak amacıyla, şekil 1'de gösterilen pasta grafiğini oluşturduk. Bu grafikte her bir dilim belirli bir arıza yüzdesini görsel bir şekilde temsil etmektedir.



Şekil 1. Arıza Dağılım Grafiği

Şekil 1, her bir dilimin belirli ettiği bir pasta grafiği sunmaktadır. Örneğin, "0.33" etiketine sahip dilim, panellerin az hasarlı olduğunu, "0.66" etiketine sahip dilim ise biraz daha hasarlı olduğunu göstermektedir. Bu görselleştirme, projemizin sonuçlarını değerlendirmemize ve derin öğrenme modelimizin belirli arıza türlerini doğru bir şekilde sınıflandırıp sınıflandırmadığını anlamamıza yardımcı olacaktır.

Bu pasta grafiği, veri setimizin arıza yüzdelerini açıkça göstererek, modelimizin güneş panellerindeki farklı arıza türlerini ne kadar doğru bir şekilde tespit ettiğine dair önemli bilgiler sunmaktadır.

E. MODEL SEÇİMİ

Bu çalışmada, güneş panellerindeki arıza tespiti için Convolutional Neural Network (CNN) tabanlı bir model kullanılmıştır. CNN, görüntü tanıma görevlerinde üstün performans sergileyen ve özellikle uzamsal özelliklerin çıkarılması konusunda etkili olan bir derin öğrenme mimarisidir. Modelimiz, evrişimli katmanlarla giriş görüntülerinden özelliklerin çıkarılmasını, pooling katmanları ile özellik haritalarının küçültülmesini ve tam bağlantılı katmanlar ile arıza yüzdesi tahminini gerçekleştirmeyi amaçlamaktadır. Özellikle, 'relu' aktivasyon fonksiyonu ve 'softmax' aktivasyon fonksiyonu, modelin öğrenme yeteneklerini artırmak için kullanılmıştır. Bu özellikler, modelin güneş paneli arızalarını başarıyla tespit etme yeteneğini artırmaktadır.

F. EĞİTİM VE TEST VERİLERİ

Derin öğrenme modelimizin eğitimi ve değerlendirmesi için, projemizdeki veri kümesini eğitim ve test setlerine bölerek adım attık. Toplamda 2624 adet güneş paneli resmini içeren veri setimizi, eğitim verileri (%60) ve test verileri (%40) olarak oranlayarak modelimizin performansını objektif bir şekilde değerlendirdik. Eğitim süreci, normale dönüştürülmüş resim verilerini içeren x_{train} ve bu resimlere ait arıza yüzdelerini içeren y_{train} ile gerçekleştirildi. Aynı zamanda, modelin genelleme yeteneğini değerlendirmek üzere ayrılan test seti, x_{test} ve y_{test} olarak belirlendi.

Elde edilen veri setinin boyutları, CNN modelimizin eğitim sürecinin ve performansının daha iyi anlaşılmasını sağlamaktadır. Bu adım, projemizin başarısını daha etkili bir şekilde değerlendirmemize olanak tanırken, derin öğrenme modelimizin güneş paneli arızalarını doğru bir şekilde sınıflandırma yeteneğini objektif bir şekilde ölçebilmemizi sağlar.

Oluşturulan Convolutional Neural Network (CNN) modelinin eğitimi tamamlandıktan sonra, test veri seti üzerinde yapılan değerlendirme sonuçları elde edildi. Modelin performansını ölçmek amacıyla kullanılan test seti, projenin başarısını değerlendirmek üzere ayrılmıştı. Elde edilen sonuçlar şu şekildedir: Test Accuracy: 70.29%

Bu sonuç, CNN modelinin güneş panellerindeki arızaları doğru bir şekilde sınıflandırma yeteneğini temsil etmektedir. Yüksek bir doğruluk oranı, modelin genelleme yeteneğinin güçlü olduğunu ve eğitim sürecinde öğrendiklerini yeni verilere başarıyla uygulayabildiğini göstermektedir. Ancak, projenin daha geniş bir bağlamda değerlendirilmesi ve modelin performansının detaylı bir analizi, daha kapsamlı bir sonuç çıkarılmasını sağlayacaktır. Bu sonuç, güneş paneli arıza tespiti konusundaki derin öğrenme tabanlı yaklaşımın başarılı bir şekilde uygulandığını ve önemli bir başarı elde edildiğini göstermektedir.

IV. BULGULAR & TARTIŞMA

Bu çalışma, güneş panellerindeki arızaların tespiti amacıyla derin öğrenme tabanlı bir yaklaşımın uygulanmasını incelemiştir. Veri setimizde yer alan güneş paneli resimleri ve bu resimlere ait arıza yüzdeleri kullanılarak oluşturulan Convolutional Neural Network (CNN) modeli, önemli sonuçlar elde etmiştir. Bulgular ve tartışmalar şu şekildedir:


Eğitim ve Test Sonuçları:

CNN modelinin eğitimi sonucunda elde edilen Test Accuracy oranı %70.29 olarak belirlenmiştir. Bu sonuç, modelin genelleme yeteneğinin yüksek olduğunu ve yeni verilere uyum sağlayabildiğini göstermektedir.

Confusion Matrix Analizi:

Oluşturulan confusion matrix, modelin her bir sınıfı ne kadar doğru ve yanlış sınıflandırdığını görsel olarak ifade eder. Tablo, modelin gerçek değerlerine (satırlar) karşı tahminlerini (sütunlar) içerir. Her bir hücre, ilgili sınıfın doğru (köşegen hücreler) veya yanlış (köşegen dışındaki hücreler) bir şekilde sınıflandırılmasını temsil eder.

Örneğin, confusion matrix'de "%33" sınıfının gerçek değerleri ile modelin tahminleri karşılaştırılır. Köşegen hücre, doğru sınıflandırmaları gösterirken, köşegen dışındaki hücreler yanlış sınıflandırmaları temsil eder. Bu görselleştirme, modelin her bir arıza kategorisini ne kadar doğru sınıflandırdığını anlamamıza ve modelin güçlü ve zayıf yönlerini belirlememize yardımcı olacaktır. Confusion matrix, dört farklı arıza kategorisinin (0%, 33%, 66%, 100%) model tarafından nasıl sınıflandırıldığını gösterir. Her bir hücre, belirli bir gerçek değeri temsil ederken, hücre içindeki sayılar o sınıfa ait tahminlerin sayısını ifade eder.



Şekil 2. Confusion Matrix

Gerçek değeri %0 olan örneklerde, modelin %0 tahminiyle doğru sınıflandırdığı örnek sayısı 525'dir.

Gerçek değeri %33 olan örneklerde, modelin %33 tahminiyle doğru sınıflandırdığı örnek sayısı 26'dır.

Gerçek değeri %66 olan örneklerde, modelin %66 tahminiyle doğru sınıflandırdığı örnek sayısı 0'dır.

Gerçek değeri %100 olan örneklerde, modelin %100 tahminiyle doğru sınıflandırdığı örnek sayısı 187'dir.

Bu sayısal değerler, modelin her bir sınıf için ne kadar doğru ve yanlış tahmin yaptığını göstermektedir. Şekil 3, confusion matrix'in görsel bir temsilini sunarak, modelin performansını daha anlamlı bir şekilde değerlendirmemize olanak tanır. Bu görselleştirme, modelin belirli arıza kategorilerini ne kadar doğru sınıflandırdığını ve nerede hatalar yaptığını daha ayrıntılı bir şekilde anlamamıza yardımcı olur.

Sonuçların Genellenmesi:

Bu çalışma, derin öğrenme modeli ile güneş paneli arızalarının tespitini başarıyla gerçekleştirmiştir. Elde edilen bulgular, güneş enerjisi sistemlerindeki arızaların otomatik tespitinin gelecekte daha yaygın ve etkili bir şekilde kullanılabileceğini göstermektedir.

Gelecekteki Çalışma İmkânları:

Modelin performansının daha da artırılması için veri setinin daha genişletilmesi ve farklı ışık koşulları, hava durumu vb. faktörlerin dikkate alınması, modelin genelleme yeteneğini artırabilir. Farklı derin öğrenme mimarilerinin ve hiperparametrelerin test edilmesi, daha etkili modellerin oluşturulmasına olanak tanıyabilir.

Bu çalışmanın bulguları, güneş panellerindeki arızaların otomatik tespiti konusundaki derin öğrenme yaklaşımının potansiyelini ortaya koymaktadır. Ancak, bu alandaki çalışmaların daha da geliştirilmesi ve genişletilmesi gerekmektedir.

V. SONUÇLAR

Modelin eğitimi tamamlandığında elde edilen %79 train accuracy ve %70 test accuracy sonuçları, güneş panellerindeki arıza tespiti konusundaki başarıyı göstermektedir. Eğitim veri setinde elde edilen yüksek doğruluk oranları, modelin bu veri setine uygun bir şekilde öğrenme yeteneğini yansıtmaktadır. Ancak, test veri setindeki bir miktar düşük doğruluk oranı, modelin genelleme yeteneğinin belirli koşullarda sınırlı olabileceğini gösterebilir. Yüksek eğitim doğruluğuna rağmen, modelin test veri setindeki performansındaki bu farklılık üzerinde durmak önemlidir. Bu durum, modelin belirli özelliklere veya veri setinin özel koşullarına aşırı uyum sağlayabileceğini işaret edebilir. Modelin genelleme yeteneğini artırmak için, gelecekteki çalışmalarda daha çeşitli ve geniş kapsamlı bir veri seti kullanılabilir veya modelin hiperparametreleri daha fazla ayarlanabilir. Sonuç olarak, elde edilen doğruluk oranları, modelin güneş panellerindeki arızaları tanımlama konusundaki yeteneğini göstermektedir.

REFERENCES

- [1] Korkmaz D. SolarNet: A hybrid reliable model based on convolutional neural network and variational mode decomposition for hourly photovoltaic power forecasting. *Appl Energy* 2021;300:117410.
- [2] Acikgoz H. A novel approach based on integration of convolutional neural networks and deep feature selection for shortterm solar radiation forecasting. *Appl Energy* 2022;305:117912.
- [3] Smith, A. et al., "Renewable Energy and the Path to a Sustainable Future." *Energy Reports*, vol. 6, 2020, pp. 178-186.
- [4] LeCun, Y. et al., "Deep Learning." *Nature*, vol. 521, no. 7553, 2015, pp. 436-444.
- [5] Wang, J. et al., "Fault Diagnosis of Photovoltaic Systems Using Deep Learning Techniques." *Solar Energy*, vol. 212, 2020, p. 804-814.
- [6] Zhang, L. et al., "Application of Artificial Neural Network in Fault Diagnosis of Photovoltaic Grid-connected Inverter." *IEEE Access*, vol. 8, 2020, pp. 143348-143359.
- [7] Gupta, R. et al., "Enhancing Fault Detection Accuracy in Photovoltaic Systems through Deep Neural Networks." *Journal of Renewable and Sustainable Energy*, vol. 13, 2021, p. 043456.
- [8] Chen, S. et al., "A Comparative Study of Machine Learning Approaches for Fault Detection in Photovoltaic Systems." *Solar Energy*, vol. 225, 2021, pp. 1-12.
- [9] Khezri R, Mahmoudi A, Aki H. Optimal planning of solar photovoltaic and battery storage systems for grid-connected residential sector: Review challenges and new perspectives. *Renew Sustain Energy Rev* 2022;153:111763.
- [10] Naveen Venkatesh S, Sugumaran V. Machine vision based fault diagnosis of photovoltaic modules using lazy learning approach. *Meas J Int Meas Confed* 2022;191:110786.
- [11] Otamendi U, Martinez I, Quartulli M, Olaizola IG, Viles E, Cambarau W. Segmentation of cell-level anomalies in electroluminescence images of photovoltaic modules.